Занятие I

ML. Линейная регрессия

1. Введение

Основные термины

- МО изучает способы выделения паттернов предметной области из ограниченного количества данных
- **Объект, *x*** - для чего мы делаем предсказание
- Объект идентичен своему признаковому описанию. Таким образом, ***x*** это комбинация всех конкретных признаков определенного объекта
- Предсказываемое целевое значение **target, *y***

1. Введение

Алгоритм Обучения

Средний доход | Жил. Площадь | Время до метро

(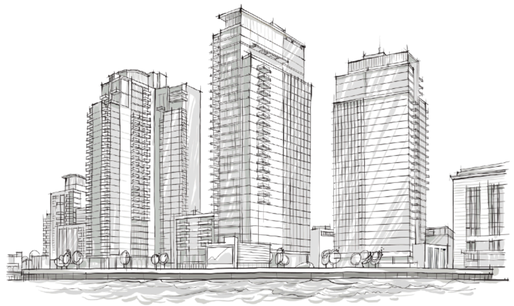 , 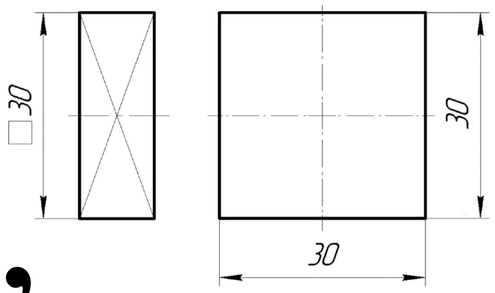 ,)

$$x_i \in \mathbb{X} = (x_i)_{i=0}^{n}$$

$$y_i \in \mathbb{Y} = (y_i)_{i=0}^{n}$$

1. Введение

Типы задач при обучении с учителем

- **Classification:**
  - ***Binary:*** $\mathbb{Y} = \{0,1\}$
  - ***Multi-class:*** $\mathbb{Y} = \{1,\ldots,K\}$
  - ***Multi-label:*** $\mathbb{Y} = \{0,1\}^k$

- **Regression**

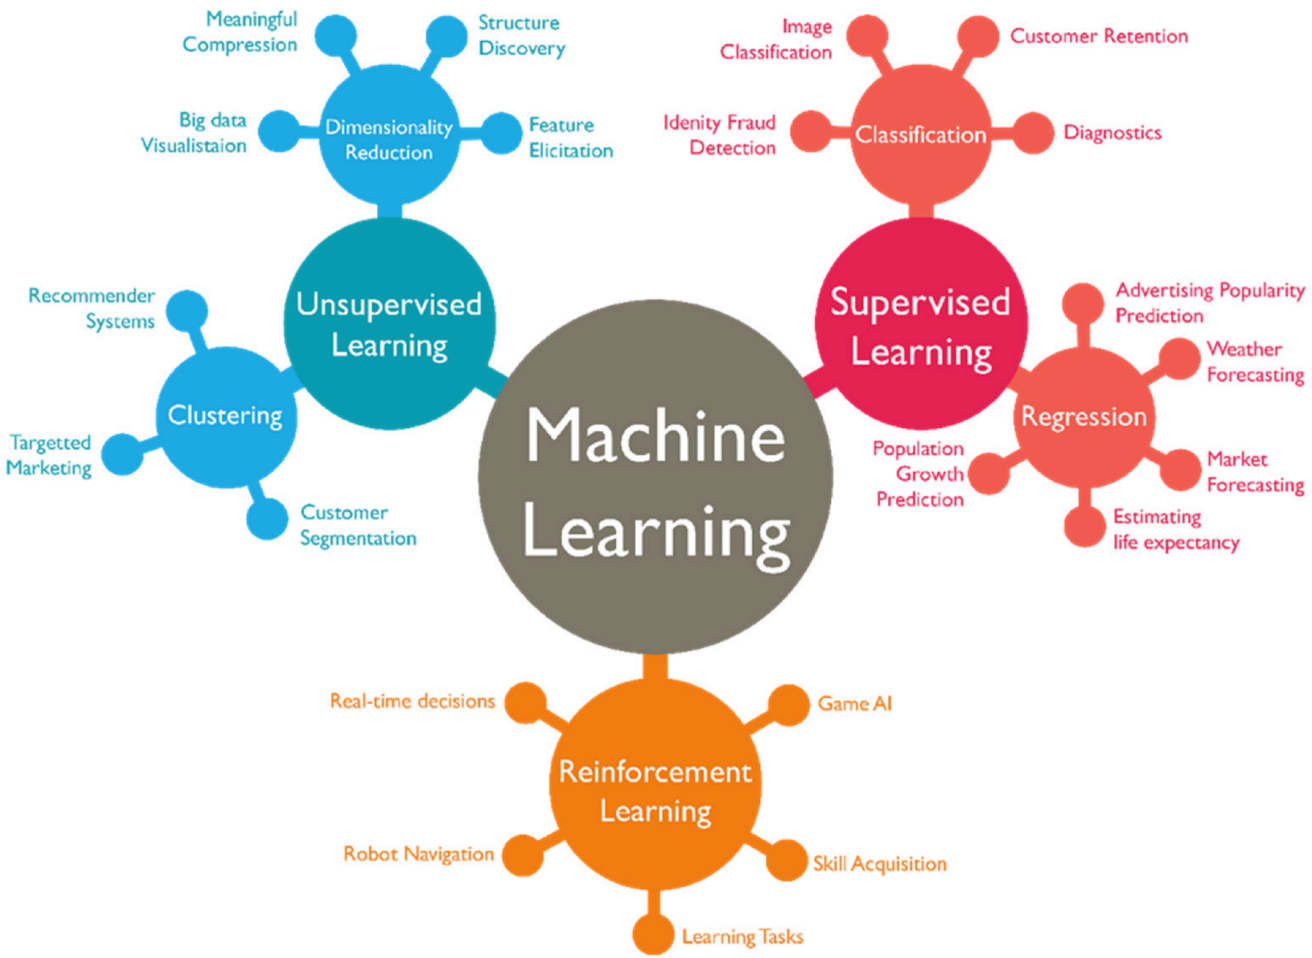

1. Введение

Алгоритм Обучения

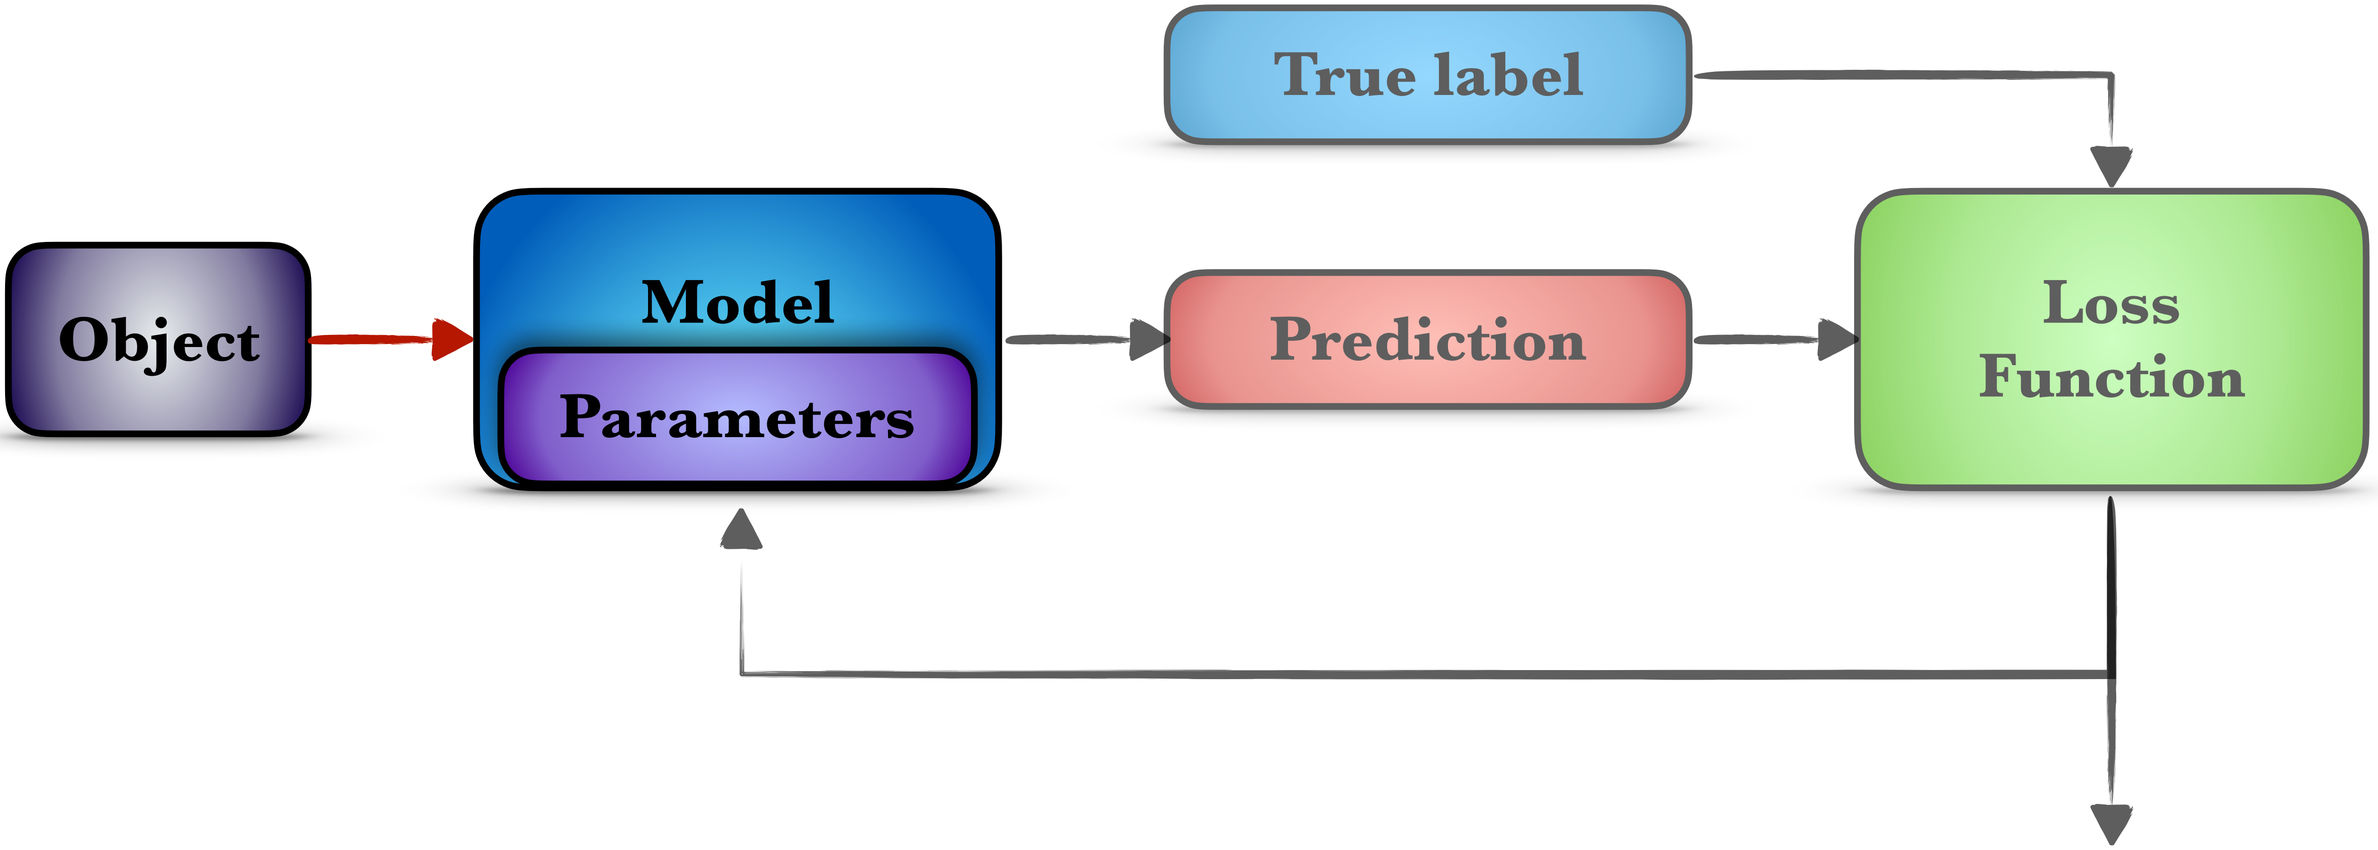

- Object’s features are passed to the initially randomly initialised model

1. Введение

Алгоритм Обучения

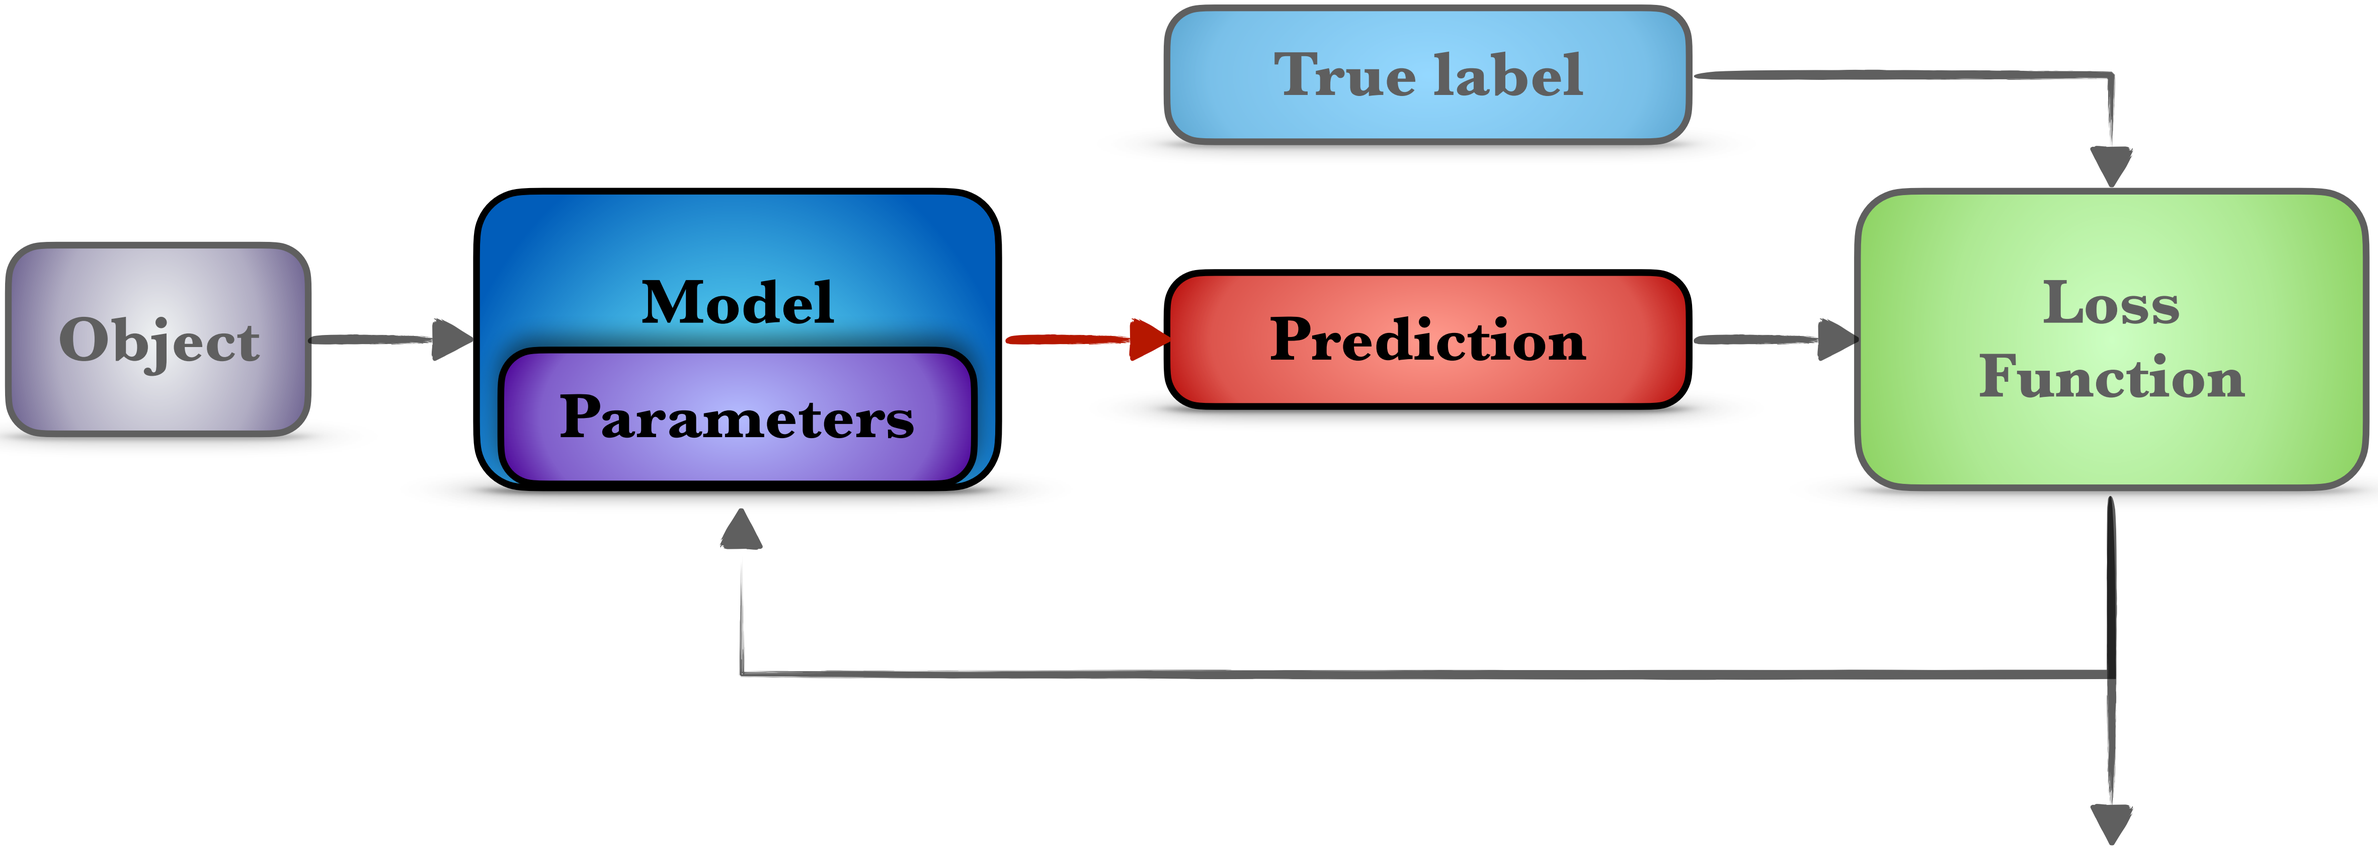

- Model makes predictions of the target variable for the object based on features

1. Введение

Алгоритм Обучения

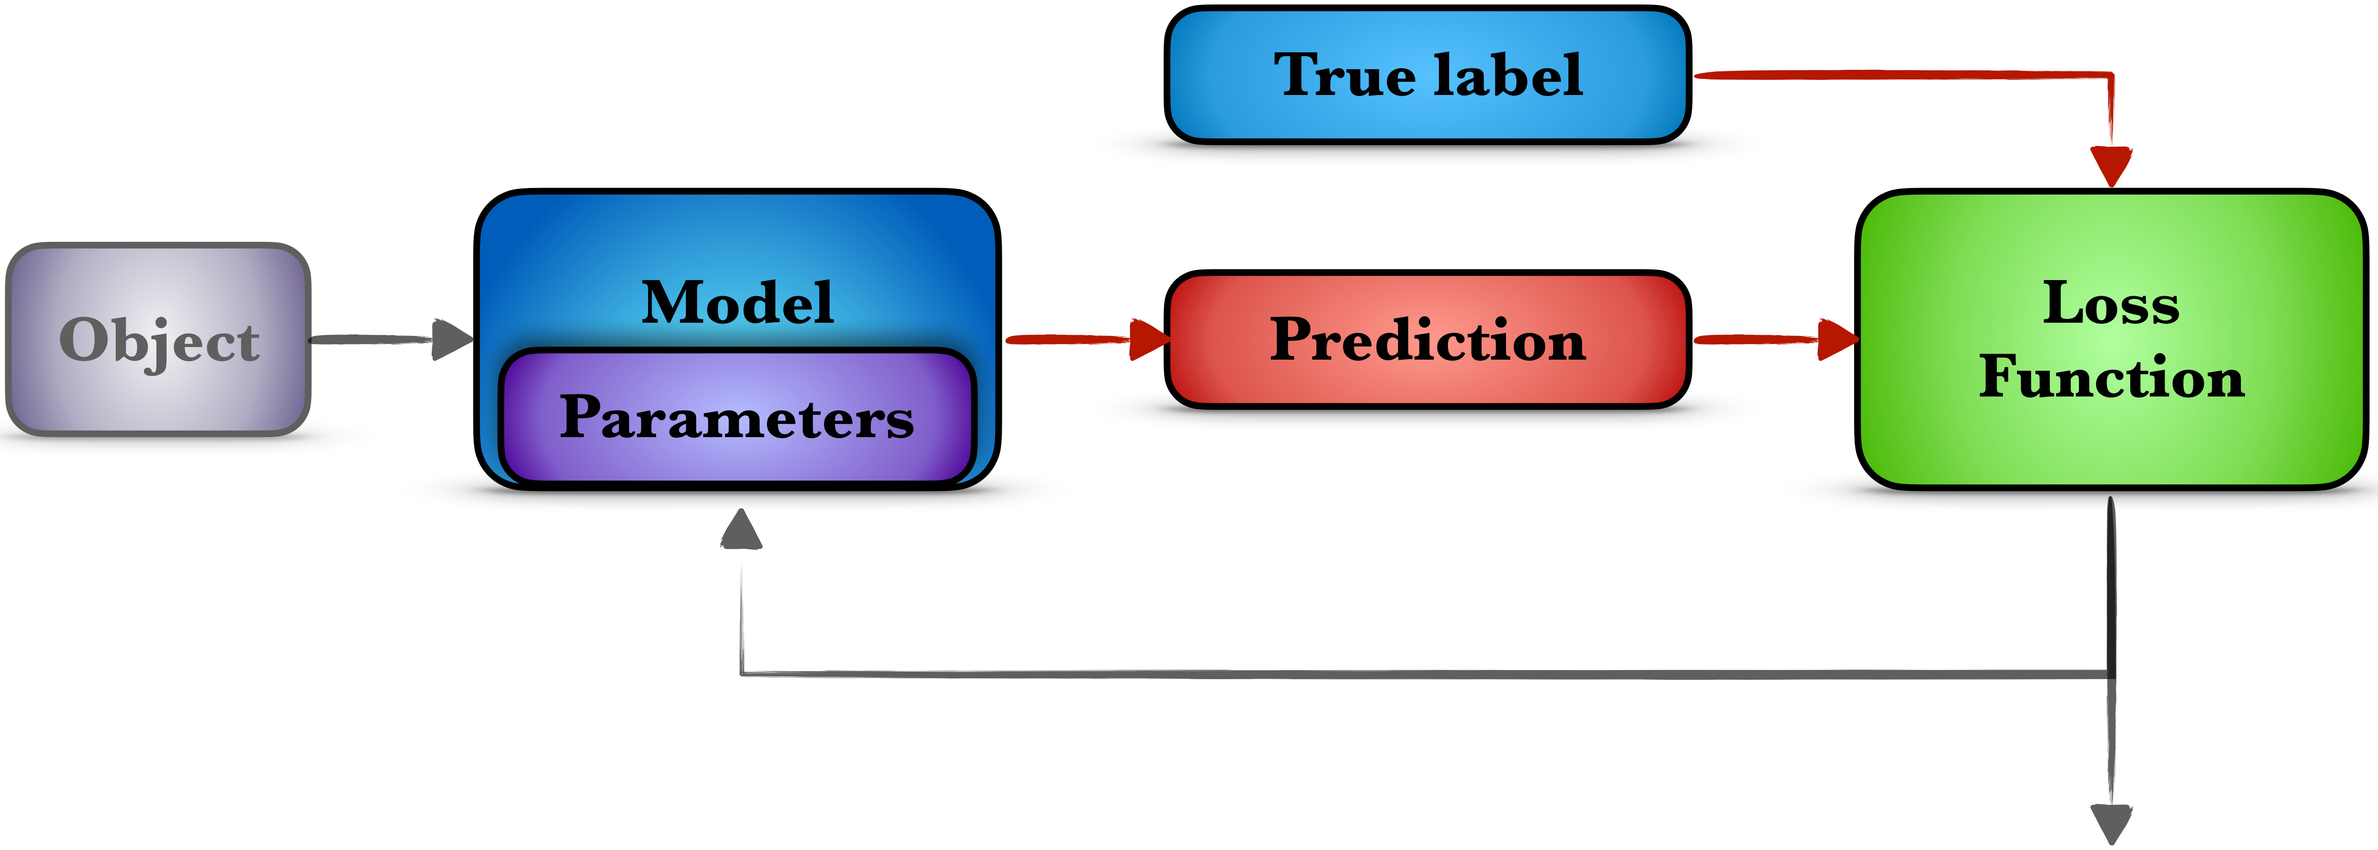

- Loss function calculates difference between predictions of model and true labels

1. Введение

Алгоритм Обучения

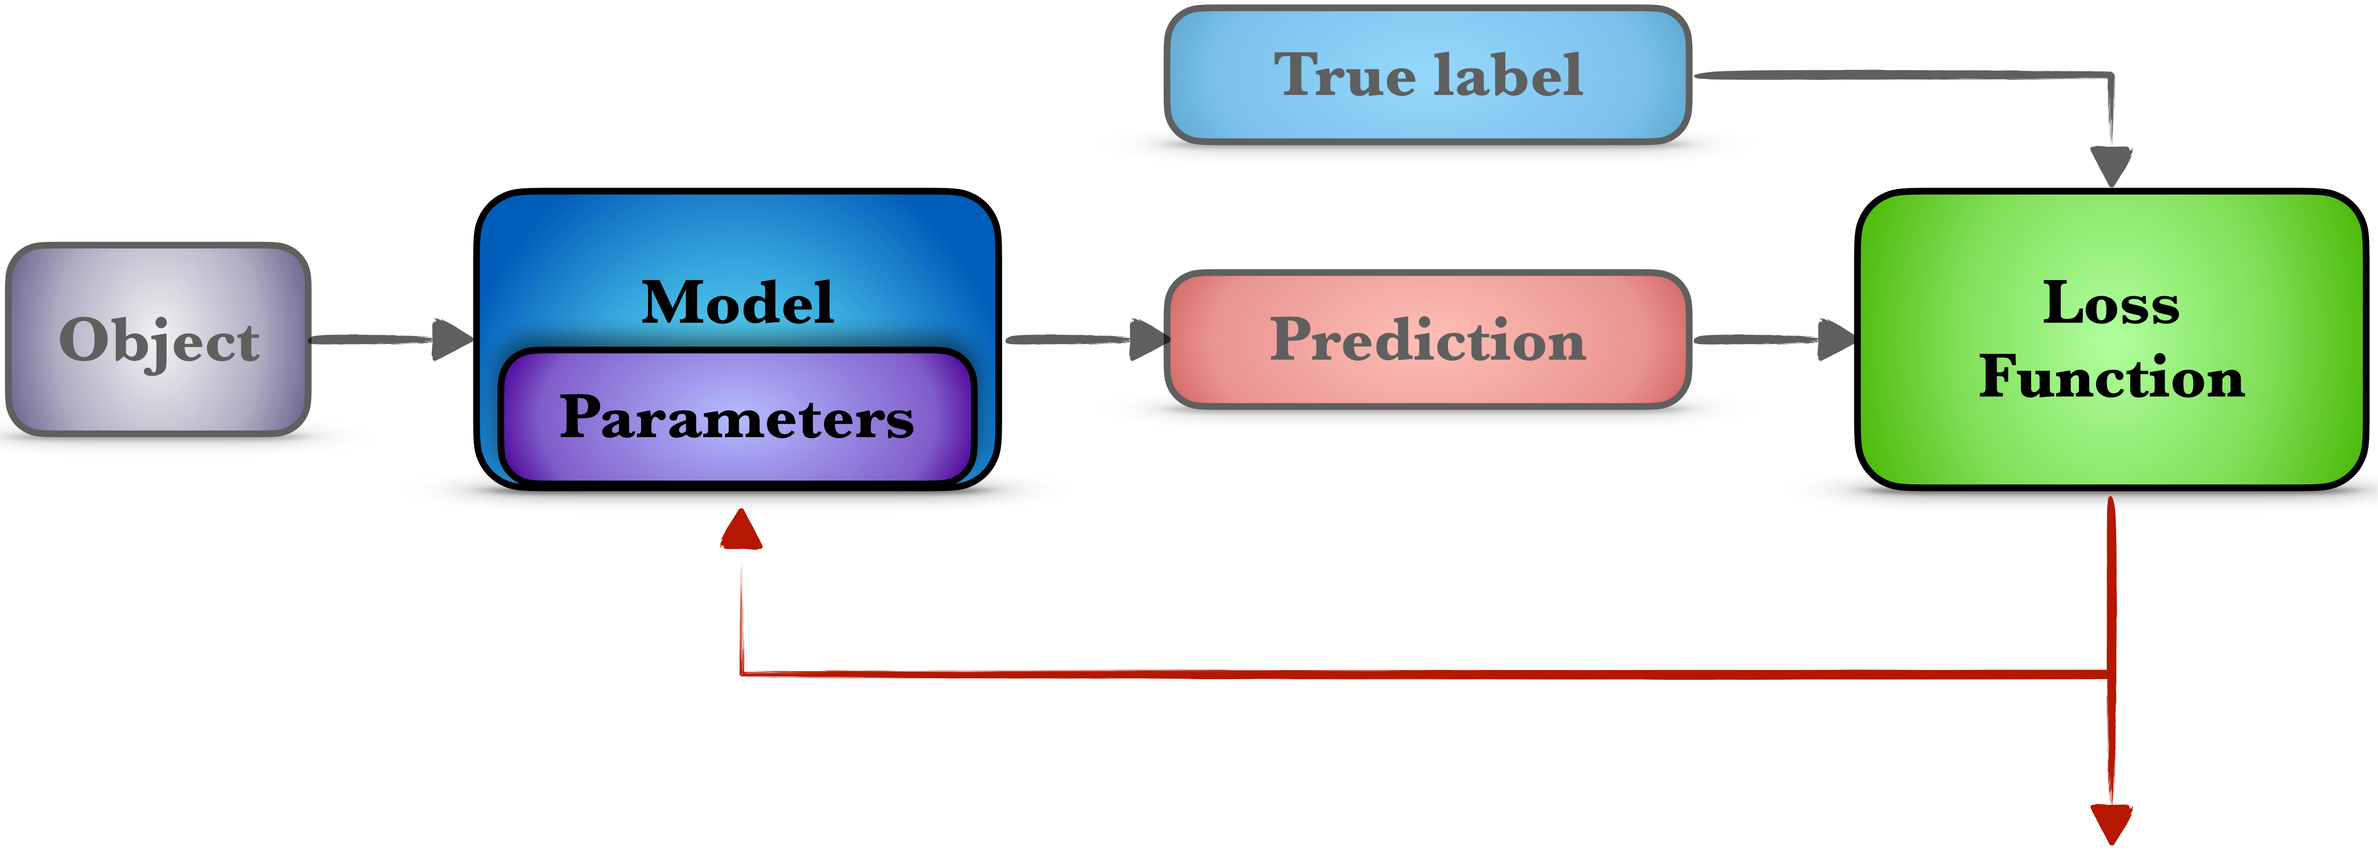

- Model’s parameters are updated based on gradient

1. Введение

Алгоритм Обучения

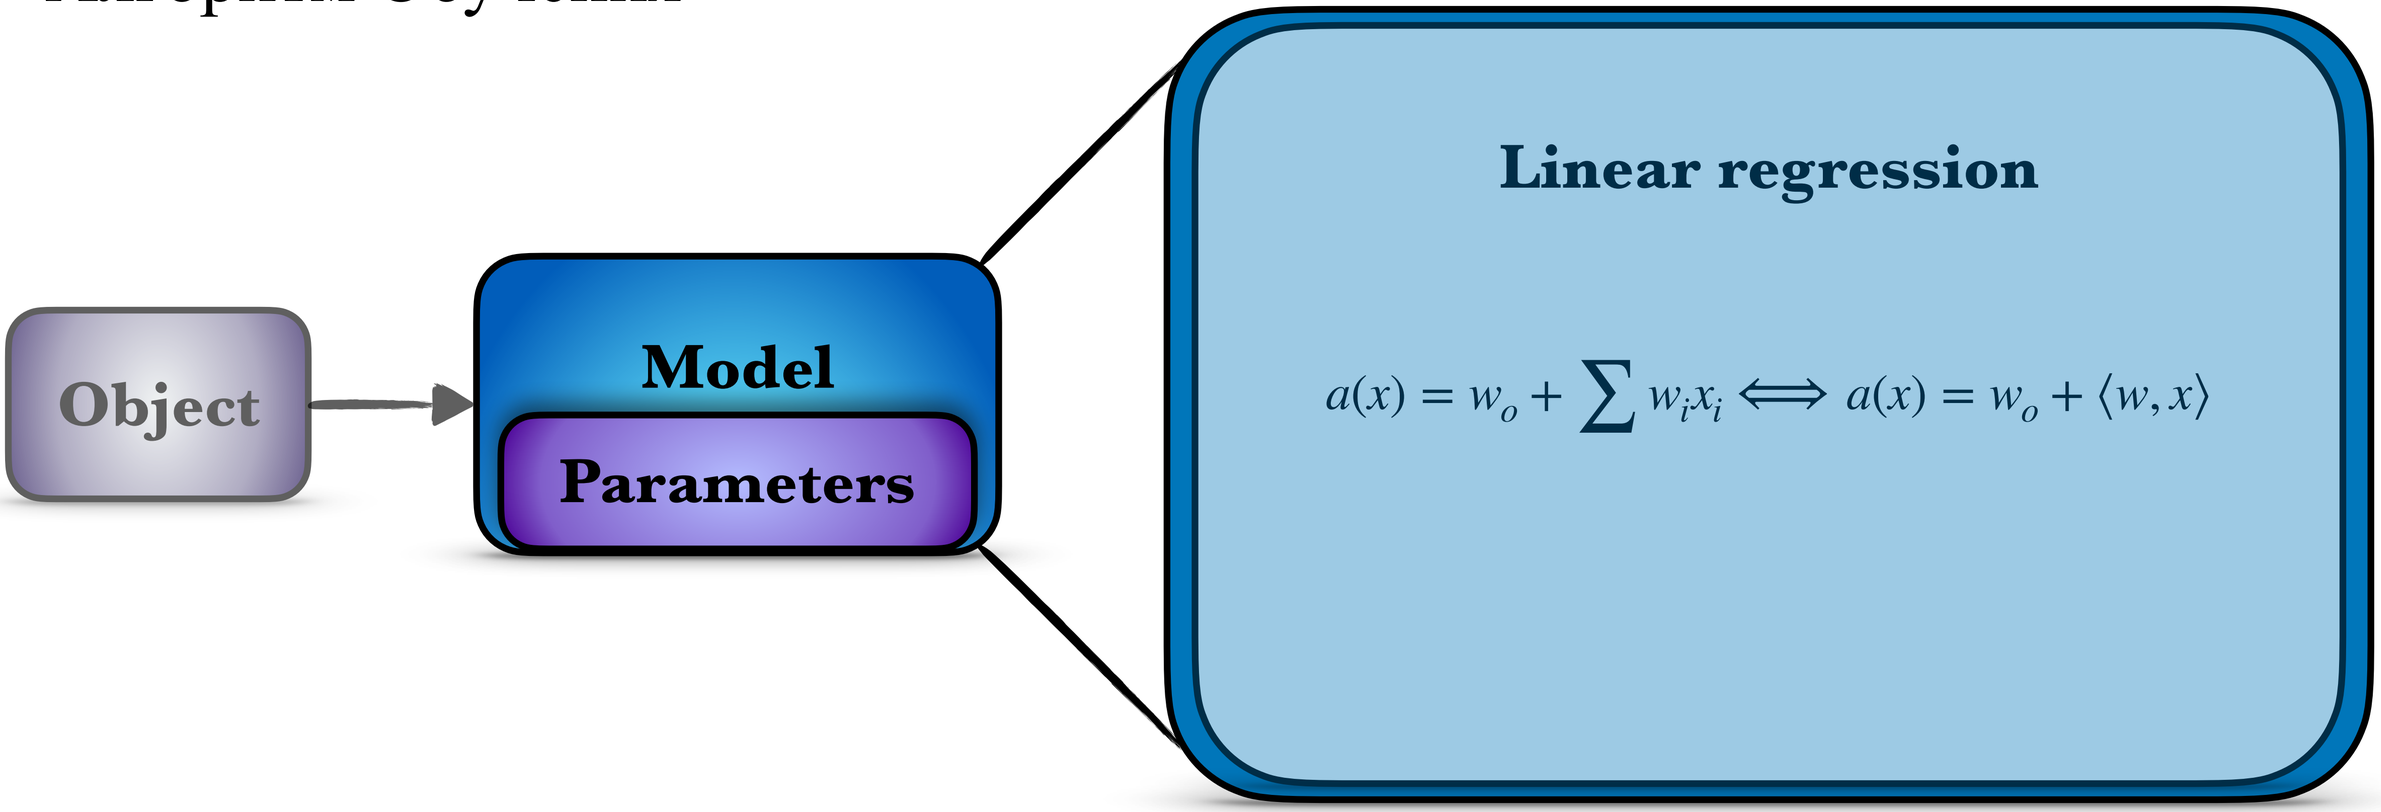

- Model's parameters are updated based on gradient

	Признаки		**Истина**
	Время до Метро	Жил. Площадь	Цена
КВ1:	**5** минут	**30** кв. м.	**10** млн.
КВ2:	**30** минут	**20** кв. м.	**5** млн.

Веса (в начале случайные)

Линейная Регрессия	w1	w2	w0
	10	8	2

a(кв1) = w1 * 5 минут + w2 * 30 квм + w0 = 50 + 240 + 2 = 292

Предсказание для первой квартиры

a(кв2) = w1 * 30 минут + w2 * 20 квм + w0 = 300 + 160 + 2 = 462

Предсказание для второй квартиры

1. Введение

Функции Потерь

Функционал ошибки $Q(a, X) = \frac{1}{\ell} \sum_i L(a, x_i, y_{true_i})$

- **Regression**
  - ***MSE***
    - Mean squared error - bad interpretation, most common
    - $L(a, x, y_{true}) = (a(x) - y_{true})^2 = (y_{pred} - y_{true})^2$
    - ***RMSE:*** $Q(a, X) = \sqrt{\frac{1}{\ell} \sum (a(x_i) - y_i)^2}$
  - ***MAE***
    - Mean absolute error - not differentiable
    - $L(a, x, y_{true}) = |a(x) - y_{true}|$

Синтаксис

$x \in X$ *один из объектов нашей выборки*

$x_i = [x_{i1}, x_{i2}, \ldots, x_{i,d}]$ *i-ый объект с d признаков*

$$X = \begin{pmatrix} x_{11} & \ldots & x_{1d} \\ \cdots & & \\ x_{\ell 1} & \ldots & x_{\ell d} \end{pmatrix}$$ *Вся наша выборка, l - кол-во объектов всего*

$y \in Y$ *Один из таргетов нашей выборки*

$a : X \to Y$ *Модель или функция, строящая предсказания по признакам*

$a(x_i) = y_{pred_i}$

$a(x_i) = w_0 + w_1 \cdot x_{i1} + w_2 \cdot x_{i2} + \ldots + w_d \cdot x_{id}$ *Линейная регрессия*

$i \in [1, \ell]$ *Индекс конкретной квартиры*

$$Q(a, X, Y) = \frac{1}{\ell} \cdot \Sigma_{i=1}^{\ell} L(a, x_i, y_{true_i})$$

Функционал ошибки = средняя ошибка по всем объектам

$$L(a, x_i, y_{true_i}) = (a(x_i) - y_{true_i})^2$$

Функция потерь для MSE

$$L(a, x_i, y_{true_i}) = |a(x_i) - y_{true_i}|$$

Функция потерь для MAE

	Признаки		Истина
	Время до Метро	Жил. Площадь	Цена
КВ1:	**5** минут	**30** кв. м.	**10** млн.
КВ2:	**30** минут	**20** кв. м.	**5** млн.

Веса

Линейная Регрессия	w1	w2	w0
	10	8	2

Предсказание модели

$$y_{pred} = \textbf{жил. площадь} \times w_2 \ + \ \textbf{время до метро} \times w_1 + w_0$$

$$y_{\textbf{КВ1}} = 30 \times 8 \ + \ 5 \times 10 + 2 = 240 + 50 + 2 = 292$$

$$y_{\textbf{КВ2}} = 20 \times 8 \ + \ 30 \times 10 + 2 = 160 + 300 + 2 = 462$$

$$L_{\textbf{КВ1}} = |292 - 10| = 282$$

$$L_{\textbf{КВ2}} = |462 - 5| = 457$$

$$Q = \frac{282 + 457}{2} = 369.5$$

1. Введение

Функции Потерь

- **Regression**
  - ***MAE***
  - ***MSE***

y	$a_1(x)$	$(a_1(x)-y)^2$	$\lvert a_1(x)-y\rvert$	$a_2(x)$	$(a_2(x)-y)^2$	$\lvert a_2(x)-y\rvert$
1	2	1	1	4	9	3
2	1	1	1	5	9	3
3	2	1	1	6	9	3
4	5	1	1	7	9	3
5	6	1	1	8	9	3
100	7	8649	93	10	8100	90
7	6	1	1	10	9	3
		MSE = 1236	MAE = 14.14		MSE = 1164	MAE = 15.43

1. Введение

Функции Потерь

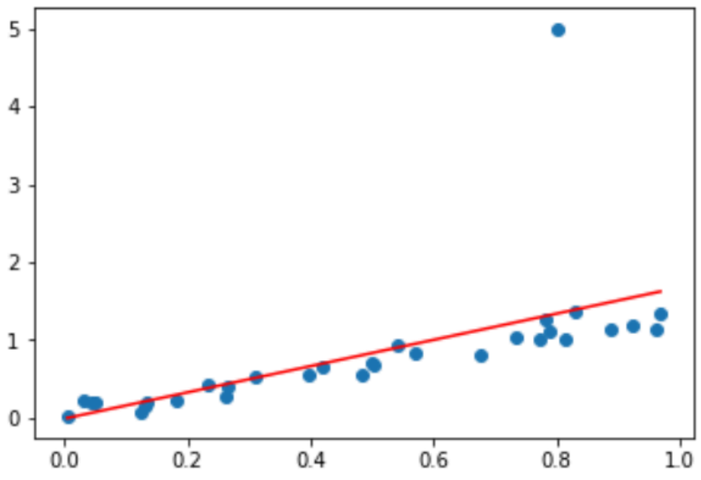

С учётом выброса

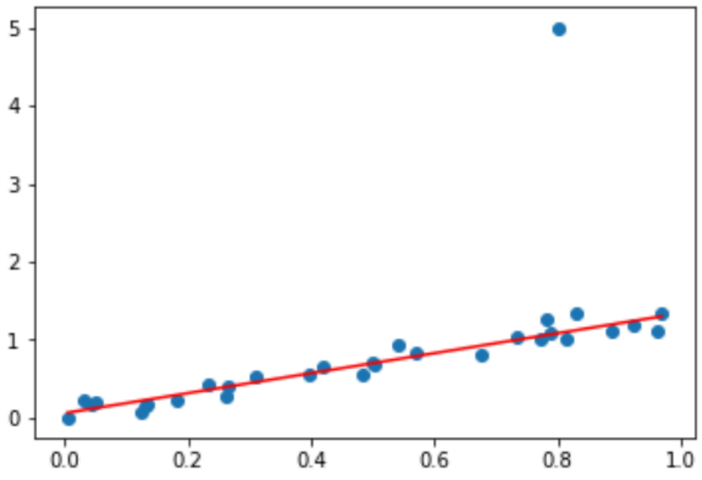

Без учёта выброса

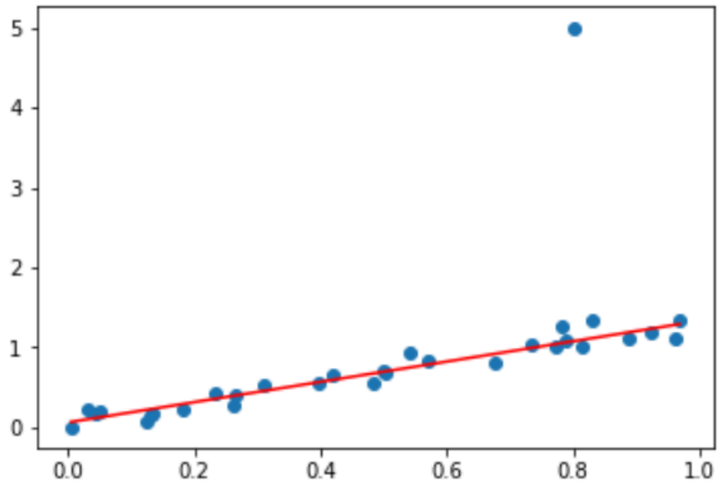

Обучение на MAE

Обучение на среднеквадратичную ошибку

1. Введение

Функции Потерь

- ***Task:*** $\alpha : \mathbb{X} \to \mathbb{Y}$ - elaborate an algorithm to predict *target* from *features*
    - Algorithm's quality control: $Q(\alpha, X) = \frac{1}{\ell}\sum_{i=1}^{\ell}(\alpha(x_i) - y_i)^2$ - *Функционал потерь*

- ***Loss function -*** measure of the error's extent for one particular sample: $L(y, z) = (y - z)^2$

$$Q(\alpha, X) = \frac{1}{\ell}\sum_{i=1}^{\ell}(\alpha(x_i) - y_i)^2$$

$$x = (x_{\textbf{метро}}, x_{\textbf{слышимость}} \dots) \to a(x) = w_o + w_1 x_1 + \dots + w_d x_d$$

1. Введение

Какие бывают признаки?

- $x_i \in \mathbb{R}$ - numerical features
- $x_i \in \{0,1\}$ - binary features
- $x_i \in C$ - categorical features

Котировка категориальных признаков

- One-Hot encoding
  - Из каждой категории делаем новый бинарный признак (Москва или нет; Питер или нет….)
- LabelEncoding
  - Каждую категорию делаем числом в рамках одного признака (Москва = 1, Псков=2, Питер = 3…)

1. Введение

Как решать проблему исключительно линейных зависимостей?

- Бинаризация признака

  Разделить на бины (интервалы) диапазон значений признака и каждый интервал сделать бинарным признаком

- Брать функции над признаками: x1^2, exp(x1), x1x2, sin(x1 + beta*x2)….